電子商務技術作業8

第一部份:Python

載入「income.csv」(預測薪水是否能超過 50K),請將資料切成訓練集與測試集 (random_state=15, test_size=0.3)並做必要的前處理。


1. 建立 KNN 模型,印出模型對訓練集、測試集的 Accuracy。(5%)

```
[19]: import pandas as pd # 5/用程件推测器 pd import numpy as np from sklearn import preprocessing import matplotlib.pyplot as plt from sklearn.model_selection import train_test_split pd.set_option('display.width',1000) df = pd.read_csv('/Users/xwlee/Desktop/ECt/hw8/income.csv')

[20]: from sklearn.preprocessing import LabelEncoder labelencoder = LabelEncoder (idf'workclass']) df('workclass') = labelencoder.fit_transform(df['workclass']) df('morkclass') = labelencoder.fit_transform(df'workclass']) df('mortial-status') = labelencoder.fit_transform(df'workclass']) df('reclationship') = labelencoder.fit_transform(df'workclass') df('rece') = labelencoder.fit_transform(df'workclass') df('rece') = labelencoder.fit_transform(df'workclass') df('rece') = labelencoder.fit_transform(df'workclass') df('nace') = labelencoder.fit_transform(df'workclass') df('native-country') = labelencoder.fit_transform(df'workclass') labelencoder.fit_drans') labelencoder.fit_transform(df'workclass') labelencoder.fit_drans') labelencod
```

2. (承上題) 當限制 feature 數量為 n 時 (n = [1, 14]) · 請為每一個 n 利用 Wrapper feature selection 技巧尋找最適合此模型的 feature set · 搜尋策略請使用 forward selection · 並以 5 Cross Validation 後的 Accuracy 為選擇的依據。(30%)

3. (承上題) 請以折線圖呈現模型在不同 feature 數量下的最佳表現。(X 軸:feature 數量,Y 軸 Accuracy)。(5%)



4. 請印出最適合此模型的 feature set。(包含 feature 數量及名稱) (5%)

```
[24]: dict = {"Number of features": b, "Accuracy": a}
       df1 = pd.DataFrame(dict)
      df1
[24]:
          Number of features Accuracy
                        2.0 0.698117
        2
                        3.0 0.730190
        3
                        4.0 0.738101
        4
                        5.0 0.747329
        5
                        6.0 0.747476
        6
                         7.0 0.745279
                        8.0 0.743668
        8
                        9.0 0.742789
        9
                        10.0 0.743668
                        11.0 0.745132
       10
                        12.0 0.744253
       11
       12
                        13.0 0.743960
       13
                        14.0 0.607882
```

5. 請使用挑選出的最佳 features 重新訓練模型 (10%), 並比較挑選前與挑選後的模型表現。(10%)


```
[29]: x1=df[['age','workclass','educational-num','capital-gain','capital-loss','hours-per-week']]
    y1=df[['income']]
    x1_train,x1_test,y1_train,y1_test=train_test_split(x1,y1,test_size=0.3,random_state=15)
    knn = KNeighborsClassifier()
    knn.fit(x1_train,y1_train.values.ravel())
    y1_test_predicted = knn.predict(x1_test)
    accuracy1 = metrics.accuracy_score(y1_test, y1_test_predicted)
    print("Before:",accuracy)
    print("After:",accuracy1)

Before: 0.6230348598769652
    After: 0.7539302802460697
```

第二部份:Weka

載入資料集 income.csv (預測薪水是否能超過 50K)。


1. 針對 RandomForest 尋找最適合此模型的 feature set,並以 00B 或 5 CV、Accuracy 為選擇的依據。請將過程與輸出結果截圖到作業中。(20%)




2. 請寫出挑選的 feature set。(並以 weka 輸出佐證) (5%)

A: 4 個 (occupation, relationship, capital-gain, capital-loss)

3. 請使用挑選前與挑選後的 features 分別建立 RandomForest (使用 00B 或 5 CV) 並 做比較(至少寫出 2 點),並將過程與輸出結果截圖到作業中。(10%)



Before



A:

- 1. 使用 feature set 之後整體的運算時間有顯著的提升
- 2. OOB 的 Correctly instance 也提升了 0.5%左右
- 3. Summary 的部分,由於我們在 After 只取用了 4 個 attribute 來建模型,所以在 Correctly instance 的部分則會有顯著的下降